Universidad del Valle De Guatemala

Facultad de Ingeniería

Deep Learning



## Laboratorio 1

Javier Mombiela 20067 Roberto Ríos 20979.

Guatemala, 30 de mayo 2023

En parejas, utilicen el código publicado en NNsimple.ipynb conteste los siguientes problemas. Analice las preguntas con la teoría vista en clase y complemente con capturas de código y resultados.

- 1. ¿Existe diferencia entre la convergencia de los parámetros (pesos y sesgos) si estos son inicializados en 0 o como números aleatorios?
  - o Iniciando con 0

Iniciando con random

Se puede mencionar que a la hora de inicializar todo como random, se puede optimizar el costo y también podemos observar como el bias y los pesos se van ajustando. Por otro lado, si se inicializa todo en 0, las neuronas están muertas, por lo que el costo se mantiene constante, ya que los cálculos no están siendo afectados. Cabe mencionar que la red proporciona predicciones erróneas con estos parámetros.

- 2. ¿Qué diferencia en la convergencia de la función de costo y los parámetros existe si el learning rate del código es 0.01? 0.1? 0.5?
  - 0.01:

## o 0.1:

0.01 es el aprendizaje más lento; sin embargo, esto asegura que se inspeccione más por cada paso, aunque este ritmo es muy lento que no llega a mejorar lo suficiente para ciertas curvas de aprendizaje. Una tasa del 0.1 podría ser más rápida, sin embargo aún no es óptima, el 0.5 es la mejor opción para este ejemplo, ya que no tiene riesgos de saltarse mínimos y empeorar a pesar de ir más rápido, por lo que solo se diferencia por aprender más rápido. En todos los casos las predicciones son correctas.

3. Implemente MSE como función de costo y propague los cambios en las funciones que lo requieran. ¿Qué cambios observa?

o Función de costo:

```
def MSE(A2, Y):
m = Y.shape[1]
cost = (1/m) * np.sum(np.square(Y - A2))
return np.squeeze(cost)
```

• Backward propagation:

```
def backward_propMSE(X, Y, cache, parameters):
A1 = cache["A1"]
A2 = cache["A2"]
W2 = parameters["W2"]
dZ2 = (A2 - Y) / m
dW2 = np.dot(dZ2, A1.T)
db2 = np.sum(dZ2, axis=1, keepdims=True)
dZ1 = np.dot(W2.T, dZ2) * (1 - np.power(A1, 2))
dW1 = np.dot(dZ1, X.T)
db1 = np.sum(dZ1, axis=1, keepdims=True)
grads = {
    "dW1": dW1,
    "db1": db1,
    "dW2": dW2,
    "db2": db2
return grads
```

o 0.01:

## 0.1:

## 0.5:

 $\circ$ 

0

Lo que se puede observar es que en general el MSE es una mejor función de costo, ya que reduce el costo mucho más que la función anterior y da predicciones correctas aun teniendo un learning rate alto.